

ARGUS

自主 AI 科学家 / Autonomous AI Scientist

商业计划书

天使 / 种子轮融资

给它一个研究目标和机器规则，剩下的它自己来：

选题 → 调研 → 设计实验 → 在**真实 benchmark** 上跑 → 分析 → 写论文 → 自审 →
改稿 → 投稿就绪。

没有人在回路里逐步审批。

日期：2026 年 6 月

版本：v1.0

文件密级：**机密 • Confidential**

联系方式：_____

目录

目录

1	执行摘要	2
2	问题：科研生产力的结构性瓶颈	3
3	解决方案：Argus —— 自主 AI 科学家	3
4	产品与技术	4
5	竞争壁垒（Moat）	5
6	市场机会	5
7	商业模式与定价	6
8	单位经济模型（Unit Economics）	7
9	竞争格局	7
10	进入市场策略（Go-to-Market）	7
11	路线图与里程碑（融资后 18 个月）	8
12	团队	8
13	财务预测（三年 · 目标值）	8
14	融资计划（The Ask）	9
15	风险与应对	9

1 执行摘要

Argus 是一个 7×24 全自主运行的“AI 科学家”。 用户只需提供两样东西——一个**研究目标**和一份**机器规则**（GPU、路径、预算等约束）——Argus 就独立地把一篇论文从无到有做出来：选题、文献调研、设计实验、在真实公开 benchmark 上完整跑、分析结果、撰写 LaTeX 论文、自我评审、反复改稿，直到达到投稿就绪。**科研所需的每一个判断都由 AI agent 自己下，没有人在回路里逐步审批。**

一句话定位：别的研究 agent 只能做到论文的“前 70%”（一个点子 + 一个玩具实验 + 一份看上去像样的 PDF）。Argus 专攻评审真正会拒稿的“后 30%”——证据不足、实验单薄、结论无据、引用造假、版面超标、产物失效、不可复现——**靠持续执行加硬性质量闸门把这 30% 补上。**

为什么是现在（Why now）：前沿大模型已经能写代码、能用工具、能长时间运行，但单个模型的上下文窗口装不下一个跨越数百步、数亿 token 的长程科研任务。**真正的瓶颈不再是“模型够不够聪明”，而是“如何让一个会遗忘的智能体，在超长任务里保持连贯、不造假、不空转”。**这正是 Argus 的工程内核所解决的问题。

我们已经建成了什么（事实，非愿景）：

- 完整的**三层 Agent 架构**（Planner / Engineer / Reviewer）+ 一根领域无关的“笨管道”harness，已可 7×24 daemon 化无人值守运行。
- **8 阶段研究流水线**（research → plan → benchmark → run → analysis → draft → review → submission），每阶段由 Reviewer 对照 checklist 裁决是否推进。
- **65 个内置 Skill**（55 个 Engineer + 10 个 Reviewer），覆盖文献检索、实验执行、消融、结论溯源、论文写作、图表生成、格式预检、投稿保障。
- **防造假诚信护栏**：强制使用真实公开 benchmark、禁止灌水、留存可审计产物——这是产品的核心，不是附加功能。
- **长程记忆 / 反遗忘上下文引擎**：跨 session 只交接“经筛选的有价值记忆”，根治长任务里的 amnesia 空转——这是我们最深的技术壁垒。
- 工程成熟度：153 个测试文件、CI（pytest/ruff/mypy）全绿、支持多会议格式（EMNLP/ACL、AAAI）。

商业机会：全球每年研发支出超过 2.5 万亿美元，每年产出数百万篇学术论文；在企业研发、量化金融、生物医药、AI 实验室中，“高水平研究人力”是最稀缺、最昂贵的资源。Argus 把“一篇可投稿论文”的边际成本从**数月人力（数万美元）**降到**数百美元的算力**，是 10–100 倍的成本结构重构。

融资诉求：本轮拟融资 **人民币 1,500 万元**（约 US\$2.1M），出让 15%–18%，用于研发团队扩张、算力/API、商业化落地与合规。18 个月内冲刺首篇端到端认证论文、10 家种子客户、ARR 突破人民币 300 万元，达到 A 轮就绪。

2 问题：科研生产力的结构性瓶颈

研究是人类最有价值、却最难规模化的劳动。一篇高水平论文背后是数月的文献阅读、实验设计、调参跑数、结果分析、反复写作与改稿。这条链路上的每一环都依赖稀缺的高水平人力，且高度串行、难以并行复制。

现有的“AI 辅助科研”工具只解决了边角问题：

- **文献类工具**（Elicit、Consensus、Scite 等）只做检索与综述，不碰实验与论文成稿。
- **通用 Coding Agent**（Devin、通用 Codex/Claude 调用等）能写代码，但不理解科研全流程，没有证据闸门，跑着跑着就开始编造结果、或在长任务里“失忆”反复空转。
- **学术界的“AI Scientist”原型**能演示端到端，但停在“前 70%”：玩具实验、薄弱证据、看上去像样但经不起评审的 PDF。

核心痛点：把一个聪明的大模型，变成一个能在数百步、数亿 token 的长程任务里保持连贯、不造假、不空转，并产出可被同行评审接受的成果的系统——这件事至今没有人真正做成。难点不在“生成”，而在长程执行的工程治理。

三个被长期低估的技术难点：

1. **长程记忆 / 上下文遗忘。** 单模型上下文窗口有限；长任务里 session 被反复有损压缩上百次，模型丢失工作记忆后会反复重读同一批资料空转（amnesia loop）。
2. **诚信与可复现。** 没有硬约束时，agent 倾向于“造一个好看的结果”而非“做一个真实的实验”——伪造图表、灌水数据行、引用占位作者。
3. **完成度判定。** “这篇研究到底做完没有 / 够不够格”无法用关键词或正则判断，需要一个真正会读产物、会下判断的评审者。

3 解决方案：Argus ——自主 AI 科学家

Argus 的设计建立在一句反直觉但关键的原则上：

“管道（harness）没有 agent 自己聪明。”

所以我们将系统严格切成两层：一切**科研判断**（这个 idea 平不平庸？证据够不够？该投了吗？）都交给 **Agent**；harness 只做**领域无关的脏活**（预算、调度、持久化、结构化 I/O、防造假护栏）。每一次“用词面去二次猜 agent”的诱惑，我们都删掉，换成结构化信号或交还给 agent——因为只要 harness 开始替 agent 做判断，它就成了系统能力的天花板。

这条哲学是 Argus 区别于其他“流水线式”研究 agent 的根本：**Argus 不是把 prompt 串起来的脚本，而是一个能自己做判断的自主研究工厂。**它的直接收益是——随着底层大模型变强，Argus 的能力上限自动抬高，而不被 harness 里写死的规则卡住。

4 产品与技术

4.1 三层 Agent + 笨管道

层	角色	职责
L4	Planner	backlog 空了排下一个任务；项目认证不达标时自动改派认证任务。
L1	Engineer	单轮执行：搜文献、写代码、跑实验、写 LaTeX；与 Reviewer 共享工作目录。
L2	Reviewer	对照当前阶段 checklist 审查，给 done/continue（附具体修复指令）/blocked。是项目是否完成的唯一事实来源。

三个 agent 都基于前沿推理模型（当前默认 OpenAI gpt-5.4），Reviewer 拥有 shell 访问权，能自己读文件、跑检查，而非依赖 harness 喂结论。harness 负责预算/限速、持久化与记忆、调度与 daemon、结构化 I/O 和防造假护栏——**只做这些，且只做这些**。

4.2 8 阶段研究流水线

research → plan → benchmark → run → analysis → draft → review → submission

每个阶段的产物由 Engineer 产出，由 Reviewer 对照该阶段 checklist 裁决是否推进。**关键在于“硬性证据闸门”**——例如：必须有全部方法/基线的完整打分行才能出论文；每一个标题数字结论都必须能溯源到原始产物；每一张图都要有真实生成的栅格图、prompt/输出哈希与审查记录；引用必须查真实性，拦截占位作者与断链。这些闸门正是把竞品的“前 70%”推到“可投稿”的关键。

4.3 长程记忆 / 反遗忘上下文引擎（核心壁垒）

这是 Argus 最深、最难被复制的工程资产，也直接回应了第 2 节的头号技术难点。

长任务的 Codex session 会涨到数亿 token、被有损压缩上百次，每次压缩都丢工作记忆，导致模型反复重读同一批文档空转（**amnesia loop**）。Argus 的修复哲学不是“加看门狗”，而是让 session **结构上短命 + 跨 session 边界只交接“经筛选的有价值记忆”**。

具体机制：

- **受控工作记忆检查点（Curated Working Memory）**：一份**有硬上限**的小状态（目标 / 已完成 / 试过但失败 / 当前阻塞 / 下一步）。上限在代码层强制——“**遗忘”本身就是一种主动筛选**，地面真相留在磁盘产物里可随时召回。
- **Reviewer 即记忆审计员**：Engineer 在回合末尾提出记忆更新提案，由 Reviewer 对照实际产物校验后落定为下一份权威检查点（提议—验证分离，防止模型自欺）。
- **结构化 Session 滚动**：一个会话活满 N 轮就主动退役、开新会话，只把检查点带过去——从结构上杜绝长 session 的退化。

这套机制可迁移到一切”长程自主 agent”场景（不止科研）：长周期软件工程、运维、金融研究、法律尽调——任何”任务远超上下文窗口”的领域，都需要这层记忆治理。它是 Argus 从”科研工具”走向”长程 agent 平台”的技术底座。

4.4 诚信护栏：防造假是产品核心

唯一正当的”硬规则”是**反作弊**：必须用真实公开 benchmark、禁止重复行灌水、强制留存可审计包。这些约束的是”作弊”而非”科研选择”，所以留在 harness 里合理。对企业客户而言，”**可审计、可复现、不造假**”是把 AI 研究产物用于**真实决策的前提**——这是 Argus 相对学术原型的关键商业护城河。

4.5 Skill 飞轮：越用越强

Skill 是给 agent 复用的横向能力（playbook），目前内置 65 个。能力缺失时由 distiller 在线蒸馏出新 skill 并回写。**每一次失败的研究尝试，都会沉淀出可复用的 skill、闸门、benchmark 代码与审计产物**，让下一次自主研究更强——这是一个随使用量自我增强的数据/能力飞轮。

5 竞争壁垒 (Moat)

壁垒	为什么难被复制
长程记忆引擎	反遗忘上下文治理是数十个版本踩坑迭代出来的工程 know-how，不是调个 prompt 能复刻的。
诚信护栏体系	一整套防造假、可审计、强复现的硬闸门，需要大量真实跑批中的失败案例反推。
反平庸评审	Reviewer agent + 阶段 checklist 体系，是”完成度判定”的事实来源，竞品多用脆弱的关键词/正则。
Skill 飞轮	越用越强的能力库，先发者积累的 skill / 闸门 / benchmark 形成数据护城河。
架构哲学	”harness 不替 agent 判断”让系统能力随底层模型升级自动抬升，不被写死规则封顶。

6 市场机会

6.1 市场分层（TAM / SAM / SOM）

层级	规模（估算）	口径
TAM	数千亿美元	全球研发（R&D）支出 > 2.5 万亿美元/年中，可被” 自主研究” 替代或增益的知识工作部分。
SAM	数百亿美元	学术机构 + 企业研发实验室 + 量化/生物医药等高研究密度行业的研究人力与工具预算。
SOM（3 年）	数亿美元	率先采用 AI 自主研究的头部实验室、AI 公司、量化基金、研发型企业的早期付费市场。

注：以上为基于公开行业口径的数量级估算，用于说明市场量级，非精确测算。

6.2 目标客户

- **AI / 算法实验室**：把研究员从格式、产物记账中解放，聚焦 idea 与评估标准；用 Argus 做大规模 idea 筛选与基线复现。
- **量化基金**：自主搜索、回测、验证因子与策略，端到端可审计——与诚信护栏天然契合。
- **生物医药 / 材料研发**：高研究密度、强复现要求的实验科学。
- **高校与研究生培养**：把导师精力从” 改格式” 转向” 判断 thesis 质量与评估标准”。

7 商业模式与定价

Argus 采用**多层组合变现**，核心是把” 研究产出” 而非” 软件席位” 作为价值锚：

模式	说明	定价锚（建议）
按研究产出计费	每完成一篇通过评审认证的研究/论文计费	单篇 US\$2,000–5,000
团队订阅（SaaS）	按” 研究席位” 包月，含一定额度的自主研究运行	US\$1,500–3,000 /席位/月
私有化部署	面向量化/药企/大厂的本地部署 + 定制领域 skill	年度许可 + 实施费
平台 / API	长程 agent 记忆与编排能力对外开放	用量计费

成本结构由真实数据支撑（非拍脑袋）。基于仓库内权威成本口径：gpt-5.4 输入 US\$1.25/M、命中缓存输入 US\$0.125/M、输出 US\$10/M。在重复跑批场景下，Engineer 的 prompt cache 实测命中率约 **95%**（单次最大成本杠杆），使长任务的 token 成本下降约 74%。系统内置单任务预算上限（默认 US\$30）与每日上限（默认 US\$180）做硬性成本护栏。

8 单位经济模型 (Unit Economics)

以”一篇通过认证的研究/论文”为单位（数量级估算，随 benchmark 重度浮动）：

项目	单篇估算 (US\$)
API 成本（三层 agent，含 95% 缓存杠杆）	150 -400
真实实验 GPU 算力	50 -300
单篇边际成本 (COGS)	~200 -700
建议售价（按产出计费）	2,000 -5,000
毛利率	~75% -90%

对照人力：一名研究生/RA 产出一篇可投稿论文，通常耗时数月、人力成本 US\$10,000-50,000。Argus 把同等产出的边际成本压到数百美元——**10-100 倍的成本结构优势**，且可大规模并行。

9 竞争格局

方案	文献	真实实验	论文成稿	诚信/复现闸门
人类 RA / 研究生	✓	✓	✓	依赖个人
文献工具 (Elicit 等)	✓	✗	✗	✗
通用 Coding Agent	部分	部分	✗	✗
学术 AI Scientist 原型	✓	玩具级	前 70%	弱
Argus	✓	✓全量	✓可投稿	✓硬闸门

我们的差异化不在”能不能生成”，而在”能不能完成”——端到端跑通、真实证据、硬性复现，加上长程记忆引擎让它真的能撑过数百步而不退化。

10 进入市场策略 (Go-to-Market)

- 1. **灯塔案例 (0→1)：**先产出 1 篇端到端通过 Reviewer 全流程认证的旗舰论文，作为可信度证明（首要里程碑）。
- 2. **种子社区 (1→10)：**定向邀请头部 AI 实验室 / 高校课题组试用，建立 mentor-in-the-loop 检查点（idea 短名单、实验设计、结论校准、终稿 go/no-go）。
- 3. **行业纵深 (10→100)：**切入量化金融与生物医药——这两个行业对”可审计、可复现”付费意愿最强，与诚信护栏天然契合。

4. **平台化**：把长程记忆与编排能力作为” 长程 agent 平台” 对外开放，超越科研单一场景。

11 路线图与里程碑（融资后 18 个月）

时点	里程碑	关键交付
M+3	灯塔论文	首篇 research→submission 端到端 Reviewer 认证论文；上线 daemon 状态/证据缺口实时看板。
M+6	种子客户	10 家实验室/团队试用；mentor-in-the-loop 检查点；扩展 benchmark 来源至公开前沿套件。
M+12	商业化启动	多领域可复用入口（NLP/CV/AI-infra）；首批付费客户；ARR 突破人民币 300 万元。
M+18	A 轮就绪	ARR run-rate 人民币 1,500 万元；私有化部署样板客户；平台 API 内测。

12 团队

（待补充——以下为结构占位，请按实际填写）

- **创始人 / CEO**：_____——研究方向、过往成果、为何是做这件事的合适人选。
- **技术负责人 / CTO**：_____——长程 agent / 大模型系统工程背景。
- **核心研究/工程**：_____——已交付完整系统（153 测试、CI 全绿、65 内置 skill）的工程能力即最好背书。
- **顾问**：_____——学术界（评审标准）与行业（量化/药企）顾问。

13 财务预测（三年·目标值）

指标（人民币）	2026 (Y1)	2027 (Y2)	2028 (Y3)
营收	300 万	2,500 万	1.2 亿
付费客户数	10	60	250+
毛利率	~70%	~78%	~82%
团队规模	12	30	70
现金状态	烧钱（产品打磨）	接近盈亏平衡	经营性现金流转正

注：以上为基于当前产品成熟度与市场假设的**目标值/情景预测**，非承诺。实际取决于灯塔案例落地速度与付费转化。

14 融资计划 (The Ask)

本轮：天使 / 种子轮，拟融资 **人民币 1,500 万元** (约 US\$2.1M)，出让 **15%-18%**，对应投前估值约人民币 7,000 万-8,500 万元，可支撑 **18 个月** runway。

资金用途：	用途	占比
	研发团队 (研究 + 长程 agent 工程)	45%
	算力 / API (benchmark 跑批、模型推理)	25%
	商业化与 BD (种子客户、行业落地)	20%
	合规、安全与运营	10%

投资人将获得：一个已建成、CI 全绿、具备稀缺长程记忆 know-how 的自主研究系统；一个随底层模型升级而自动增益、随使用而自我增强的能力飞轮；以及切入“AI 替代高水平研究人力”这一万亿级结构性机会的早期席位。

15 风险与应对

风险	应对
学术伦理 / AI 论文接受度	定位“研究加速器 + mentor-in-the-loop”，全链路可审计、可溯源，人类保留终审；面向企业研发场景规避会议政策争议。
对单一模型供应商依赖	harness 已抽象多后端 (backend 可切换)，降低对单一供应商锁定。
幻觉 / 造假	诚信护栏是产品内核而非附加：真实 benchmark、禁止灌水、强制审计包。
长程任务退化 / 失忆	自研反遗忘记忆引擎 + 结构化 session 滚动，已在数十版本迭代中验证。
成本失控	单任务/每日预算硬上限 + prompt cache 95% 命中杠杆，成本可控可观测。

本文件包含前瞻性陈述与基于公开口径的估算，仅供本轮融资评估之用，不构成投资承诺或要约。市场规模与财务预测为情景假设，实际结果可能存在重大差异。

机密 • Confidential