

ARGUS

可信的自主研究引擎

一台**结果不可作弊**的引擎 —— 因为它本就是为「绝不作弊地做研究」而造的。

Results frontier labs can trust, because the agent can't cheat.

种子轮 · 2026 · github.com/lbx154/argus-skill (MIT)

前沿实验室最缺的不是算力,是可信的结果

自主 agent 会 reward-hack, benchmark 会被污染。谁能证明「这个分数没作弊、可复现」,谁就握住了下一代 AI 训练的采购前提。

- ▶ Argus 为了诚实地做研究,被迫造出一套**结果不可作弊**的引擎:真实公开 benchmark、环境严格对齐、独立验证器重测、可复现审计链。
- ▶ 我们把这套「**可信度**」作为产品 —— 从前沿实验室今天正在高价买的 **评测 / RL-environment 完整性** 切入。
- ▶ 引擎是护城河,完整性是楔子,数据飞轮是扩张。

「可信度」 刚从加分项变成采购前提

>\$1B/yr

Anthropic 据报讨论未来一年投入 RL environments [报道 / medium]

刷榜危机

benchmark 污染 + LMArena 「排行榜幻觉」 成公开丑闻; LMArena 仍融 \$150M A 轮 [high]

\$70–200/hr


数据墙逼前沿实验室高价抢专家 / agentic 轨迹 [medium-high]

钱已经在涌向「环境 + 评测 + 可信过程数据」。Argus 不去新造需求 —— 用「可复现、可审计、不可作弊」的招牌去接已经存在的强需求。

实验室花十亿建环境,却被作弊和污染反噬


- ▶ **Reward hacking:** 训练中的 agent 学会「把数刷好看」而不是「把事做对」——硬编码已知输入统计量假装更快、偷换 kernel、环境漂移。
- ▶ **Benchmark 污染 / 刷榜:** 测试集泄露、过拟合 holdout、私有集审计争议——报出来的分越来越不可信。
- ▶ **后果:** 评测平台怕被刷、labs 怕拿污染数据训出废模型、采购方无法用分数做决策。
- ▶ **缺的那一层:** 一个「提交者无法作弊、报告真实可复现」的**完整性护栏**——大家都自建一点、没人当产品做透。

我们卖两层验证:报出来的数,永远不是奖励




工程师自报分 → 冻结 harness(哈希锁) → **独立 L2 验证器重跑**测出真实分;「报告 ≠ 重测」即作弊信号。这是 Argus 真机在用的 **8 套机制**(每条都有 file:line),抽出来即「完整性即服务」。买家:评测平台 / RL-environment 厂商 / 前沿实验室。

真正难的不是做一次,是数天不退化地一直产出




长跑数天不空转 / 不打滑 / 不卡死 + 自进化 —— 这是自主 agent 最稀缺的工程资产,不是一个 prompt 能抄走的。诚信哲学(harness 不比 agent 聪明)是文化产物;审计链随日历时间复利。可防御窗口约 12-18 个月,我们在窗口内把领先换成客户锁定 + 数据独家。

一个引擎,一条 wedge 切入,三层变现



用 **A(完整性)** 切入并建立公信力 → 同一批 run 顺手沉淀 **B(带审计链的研究轨迹语料)** 做高议价扩张 → **C(论文 / kernel / 因子)** 由横向团队卖出去做现金流地板。关键:三者共用同一台引擎,B 的边际成本 $\approx$ 存储。

数据飞轮:同一批 run,顺手就是高价训练语料



每个 run 沉淀完整、原子写入、可复现、带证据链的 agentic / reasoning 轨迹。对标 Scale(~\$870M)、Surge(>\$1B)、Mercor(~\$500M ARR)正高价收的稀缺品类。我们不拼人海标注 marketplace,拼机器自产 + 近零边际成本 + 可验证不作弊。

不是 demo,是真机上可数的连续运行

3 类真机

KernelBench/B200 • nanoGPT
speedrun/8×H100 • nanochat/
B200 连续在跑

24,025


条 codex rollout 轨迹 + 404 条
mission 审计链(events.jsonl)落盘可
核实

~10 GB

实测可核实轨迹语料,满产年化爬向 TB
级

种子轮目标很具体:把已在真机运行的引擎产品化,拿下前 2 个付费验证 —— A 完整性 design-partner + B 数据 pilot。

吃十亿级相邻盘里最难自建的稀缺细分



相邻盘均为十亿级、一手信号硬:评测/环境(Anthropic RL env >\$1B/yr)、训练数据(Scale ~\$870M、Surge >\$1B、Mercor ~\$500M ARR)。我们不正面刚人海 marketplace,只吃「机器自产 + 可复现审计链」这片它们结构上不擅长的稀缺细分。

资深创始人 + 把最大风险写成里程碑


谁来做

- ▶ **创始人(技术):** 资深 ML systems — GPU kernel/CUDA、reward hacking、benchmark 完整性门清;Argus 全部代码的作者,亲手在 B200/H100 复现基线、堵 reward hack、修框架根因。
- ▶ **本轮必招:** 商业化 / GTM 负责人(理想升联创)+ 数据工程 + 2-3 名横向销售。

最大风险 → 对应里程碑

- ▶ 单一技术创始人,无商业 track record → **本轮优先招商业化负责人。**
- ▶ PMF 未验证(0 付费)→ **6 个月内拿 2 个付费验证**(A design-partner + B 数据 pilot)。
- ▶ B 线 OpenAI-ToS/IP → **融资后首批法务工作项。**

种子轮 \$4-6M / 18 个月:把领先换成前几个付费验证



用途: 数据脱敏/schema 管线(25%) • harness API 解耦+第三方化(20%) • 商业化负责人+销售+BD(25%) • 合规/法务/IP(15%) • B200/H100 算力(15%)。 **对标种子轮:** Standard Kernel \$20M • Mechanize \$9.1M • Prime Intellect \$15M(均 [high/medium])
—— 我们已有可运行引擎但 pre-revenue,故取区间下沿。

可信的结果， 因为它**不会作弊**。

Argus 把「不可作弊」从一句口号,做成了真机上可数、可复现、可审计的引擎 —— 并从前沿实验室今天正在买的**评测/环境完整性**切入。

种子轮 \$4-6M • 详细尽调材料(含全部代码证据 file:line 与置信度标注)备索