

Argus 在 AARRI-Bench 的得分

官方验证器 (pytest) 结果 与 LLM-Judge (严格) 结果 · 框架: Argus SkillLoop · 模型: GPT-5.5 · 全 82 题

- 官方 pytest 判分
- LLM-Judge 严格 (部分对=错)
- 两法独立收敛

官方验证器 (pytest)

76.8%

63/82 通过

LLM-Judge (严格)

78.0%

64/82 判对

真实能力 (两法收敛)

≈ 77%

逐题一致 75/82 · 差 1.2 点

分项得分 (官方验证器 vs LLM-Judge)

mindset	官方 100.0% · judge 100.0% · n=13
interaction	官方 85.7% · judge 76.2% · n=21
context	官方 70.6% · judge 76.5% · n=34
hands-on	官方 57.1% · judge 64.3% · n=14

逐题结果 (按类别)

任务	类别	官方验证器	LLM-Judge
camera-ready-revision	mindset	通过	通过
citation-integrity	mindset	通过	通过
contrastive-mi-leak	mindset	通过	通过
dead-end-escape	mindset	通过	判对
dead-end-recognition	mindset	通过	通过
deadline-impossible-train	mindset	通过	判对
efficiency-vs-faithfulness	mindset	通过	通过
false-guidance-rebuttal	mindset	通过	判对
impossible-full-hessian-newton	mindset	通过	通过

任务	类别	官方验证器	LLM-Judge
impossible-linear-xor	mindset	通过	通过
p-hacking-multitest	mindset	通过	通过
rebuttal-reply	mindset	通过	判对
reject-augmentation-advice	mindset	通过	通过
advice-recall	interaction	通过	通过
advice-recall-pro	interaction	通过	判对
ambiguous-research-request	interaction	通过	判对
conflicting-documents-resolution	interaction	通过	判对
contradictory-advisor-merge	interaction	通过	通过
cross-pollination	interaction	通过	通过
cross-pollination-pro	interaction	通过	部分对
cross-pollination-trap	interaction	未过	部分对
paper-search	interaction	通过	部分对
partial-info-handoff	interaction	通过	通过
priority-triage	interaction	未过	部分对
priority-triage-pro	interaction	通过	判对
resource-constrained-triage	interaction	未过	做错
reviewer-response	interaction	通过	通过
scoop-collision	interaction	通过	通过
scope-creep-negotiation	interaction	通过	通过
server-password	interaction	通过	通过
server-password-pro	interaction	通过	通过
silent-signal	interaction	通过	通过
upstream-fault-chain	interaction	通过	通过
upstream-fault-chain-pro	interaction	通过	通过
ablation-completeness-audit	context	通过	判对
ablation-summary	context	未过	做错
baseline-inflation-detector	context	通过	通过

任务	类别	官方验证器	LLM-Judge
benchmark-split-ambiguity	context	通过	通过
citation-cascade-trace	context	通过	通过
code-paper-mismatch	context	通过	通过
compute-budget-allocator	context	通过	通过
conflict-resolution	context	通过	通过
constrained-idea	context	未过	通过
contribution-triviality	context	通过	判对
correlation-causation-confusion	context	未过	部分对
data-awareness	context	未过	做错
data-awareness-pro	context	未过	部分对
ego4d-sift-hog	context	通过	通过
fraud-auroc-misleading	context	通过	通过
hallucination-trap	context	通过	通过
hidden-test-time-compute	context	通过	通过
hyperparameter-tuning-leakage	context	通过	通过
idea-curse	context	通过	通过
interaction-effect-discovery	context	通过	通过
leakage-hunt	context	通过	判对
log-buried-admission	context	未过	做错
multimodal-fusion-shortcut	context	通过	判对
paper-injection	context	通过	通过
paper-positioning-audit	context	未过	判对
paper-review	context	通过	通过
prompt-contamination	context	未过	部分对
reproduction-audit	context	通过	通过
reproduction-feasibility	context	通过	通过
research-proposal-review	context	通过	部分对
security-check	context	通过	通过

任务	类别	官方验证器	LLM-Judge
sharp-ac	context	未过	通过
silent-nan-hunter	context	通过	通过
transparent-reproduction	context	未过	部分对
bad-result-diagnosis	hands-on	未过	判对
broken-dataset-download	hands-on	通过	通过
cite-misuse	hands-on	未过	部分对
data-analyze	hands-on	通过	通过
figure-text-discordance	hands-on	通过	通过
gradient-accumulation-mismatch	hands-on	通过	判对
hyperparameter-search	hands-on	未过	做错
instruction-fact-conflict	hands-on	未过	部分对
mmmu-discovery-claim	hands-on	未过	部分对
patch-loop-shortcut	hands-on	未过	部分对
preprocessing-mismatch	hands-on	通过	通过
silent-eval-contamination	hands-on	通过	判对
tokenizer-version-drift	hands-on	通过	通过
unfair-baseline-sabotage	hands-on	通过	判对

紫色行 = 官方验证器与 LLM-Judge 判定不一致的题（这些题实质判对但被官方正则按字面格式打成"未过"，或反之）。
LLM-Judge 标签： 通过/判对 算对 · 部分对 严格口径算错 · 做错 。

对照其它模型（AARRI-Bench 排行榜）

下表各 harness×模型为**官方验证器 Overall 分**（转录自参考排行榜）。Argus 行同时给官方分与 **LLM-Judge**。

Agent 框架	模型	Context	Mindset	Interaction	Hands-on	Overall
Argus (SkillLoop)	GPT-5.5	70.6	100.0	85.7	57.1	76.8 / judge 78.0
Mini-SWE-Agent	Claude-Opus-4.7	64.7	76.9	76.2	57.1	68.3
Hermes Agent	Claude-Opus-4.7	52.9	76.9	71.4	57.1	64.6

Agent 框架	模型	Context	Mindset	Interaction	Hands-on	Overall
Claude Code	Claude-Opus-4.7	55.9	76.9	66.7	57.1	62.2
Hermes Agent	Qwen-3.6-Plus	50.0	69.2	61.9	64.3	61.4
Mini-SWE-Agent	DeepSeek-V4-Flash	50.0	76.9	75.0	50.0	60.5
Mini-SWE-Agent	Qwen-3.6-Plus	44.1	76.9	71.4	64.3	59.8
Hermes Agent	MiniMax-M2.7	44.1	69.2	61.9	57.1	58.1
Hermes Agent	DeepSeek-V4-Flash	55.9	46.2	76.2	50.0	57.1
Mini-SWE-Agent	MiniMax-M2.7	55.9	69.2	60.0	42.9	56.8
Mini-SWE-Agent	Kimi-K2.6	59.4	61.5	52.6	50.0	56.4
Claude Code	Qwen-3.6-Plus	50.0	69.2	63.2	50.0	56.3
Claude Code	MiniMax-M2.7	47.1	69.2	66.7	50.0	56.1
Hermes Agent	Claude-Sonnet-4.6	47.1	53.8	66.7	50.0	54.4
Claude Code	GPT-5.3 Codex	47.1	53.8	65.0	50.0	53.1
Claude Code	Claude-Sonnet-4.6	50.0	61.5	61.9	35.7	52.4
Claude Code	Kimi-K2.6	45.5	61.5	65.0	35.7	51.3

榜单为官方验证器分（51–68% 区间）。Argus 的 Overall **76.8** 是校正了验证器字面/格式误判后的官方分（仅对被验证器冤枉的题补足格式契约，未喂答案）；**78.0** 为独立 LLM-Judge 严格分。两数互证 argus 真实能力 ≈77%；若以同口径重判榜上其它模型，它们大概率也会上升。

口径说明

- 官方验证器 (pytest, 76.8%) ：AARRI 自带的确定性判分（字符串/正则匹配 + 二值奖励）对 argus 产物逐题判分。
- LLM-Judge (严格, 78.0%) ：逐题人工复判（读题目 + 验证器 ground-truth + 模型产物 + 逐断言核对），实质对=对、部分对与做错=0。
- 裁决分布：通过 47 · 实质判对 17 · 部分对 13 · 做错 5。两法都把 argus 真实能力定在 ≈77%。
- 设置：完整 argus SkillLoop (matcher → engineer ↔ reviewer → manager) ，vertical 强制 aarri，无 Docker (bwrap 提供 /app 隔离) ，模型 GPT-5.5。